

Précisions

Soit une séquence indexée par $j \in \mathbb{N}$, où chaque élément x_j peut représenter un document, un signal, un vecteur ou un terme.

La distance $\theta \in [0, 1]$ est la distance mesurant la proximité entre ces éléments, éventuellement modulée par une fonction $f(\theta)$.

Le seuil $R \in \mathbb{R}^+$ correspond à une variable réelle d'entrée, utilisée principalement pour des signaux ou des séquences continues, tandis que $N \in \mathbb{N}$ est un seuil entier, adapté aux vecteurs, documents ou termes discrets.

Le symbole $*$ désigne un produit commutatif quelconque, servant à exprimer la rigueur ou la modulation du seuil dans les inégalités.

—

Équations avec seuil réel R (pour signaux, séquences) :

$$x_j \geq R * (1 - \theta), \quad f(x_j) \geq R * (1 - \theta), \quad f(x_j) \geq R * (1 - f(\theta))$$

Équations avec seuil entier N (pour vecteurs, documents, termes) :

$$x_j \geq N * (1 - \theta), \quad f(x_j) \geq N * (1 - \theta), \quad f(x_j) \geq N * (1 - f(\theta))$$

Cas particulier des documents, avec df_j la fréquence relative des documents contenant le terme j :

$$\text{df}_j \geq N * (1 - \theta), \quad \text{df}_j \geq N * (1 - f(\theta))$$

—

Variantes avec inégalité stricte :

$$x_j > N * (1 - \theta), \quad \text{df}_j > N * (1 - \theta), \quad \text{df}_j > N * (1 - f(\theta))$$

—

Notations et définitions clés :

- $x_j, f(x_j), \text{df}_j$: éléments d'une séquence (documents, signaux, vecteurs, termes)
- θ : distance proprement dite, élément central de la mesure de proximité
- $f(\cdot)$: fonction d'évaluation ou modulation, appliquée sur les données ou la distance
- $R \in \mathbb{R}^+$: seuil réel, adapté aux séquences et signaux continus
- $N \in \mathbb{N}$: seuil entier, utilisé pour les données discrètes (vecteurs, documents, termes)
- df_j : fréquence relative des documents contenant le terme j , importante en traitement de texte et statistiques documentaires
- $*$: produit commutatif quelconque, permettant de moduler le seuil dans les inégalités
- Les inégalités peuvent être strictes ($>$) ou larges ($\geq$) selon la précision requise

Ces équations fournissent un cadre formel pour évaluer la précision ou la correspondance dans diverses séquences de données, vecteurs, signaux et documents, en tenant compte de la nature des éléments, de la distance propre et des seuils adaptés.